

# 图像分类模型的机器逆学习：复现、评估与保留感知改进

开题答辩

2026 年 8 月

李宇晗 · 窦宇浩

# Contents



|                            |    |
|----------------------------|----|
| 1 研究背景与目标 .....            | 3  |
| 2 任务一·理解 Amnesiac .....    | 7  |
| 3 任务二·复现 Bad Teacher ..... | 9  |
| 4 任务三·完善评估指标 .....         | 12 |
| 5 任务四·保留感知改进 .....         | 14 |
| 6 进展与计划 .....              | 17 |
| 7 总结 .....                 | 21 |

# 1 研究背景与目标



- 合规与安全要求：从已训练模型中**移除某些数据的影响**（“被遗忘权”、修复被污染/错标的数据）；
- 但**删数据**  $\neq$  **删影响**，而从头重训代价太高  $\rightarrow$  催生“近似逆学习”；
- 现有方法多数只用**遗忘集准确率**判断成败，未必真忘（Hayes 2024）。

## 本文目标

让模型可靠地忘掉一个指定类别、保住其余类别，并能**验证**它真的忘了。

# 研究内容：四项任务



围绕指南的四项任务展开：

| 任务   | 内容                       |
|------|--------------------------|
| 一·理解 | 运行 Amnesiac，调超参分析遗忘影响    |
| 二·复现 | 复现 Bad Teacher，补全其蒸馏训练核心 |
| 三·评估 | 在准确率外引入 MIA、ZRF 两个指标并分析  |
| 四·改进 | 提出“保留感知”改进，并对照验证         |

## 相关工作

本文沿**蒸馏路线** (Bad Teacher、SCRUB)，参照近年评估研究 (Hayes 2024、Deep Unlearn 2024) 补隐私指标；另有 SISA、SalUn 等路线可参考。

---

|                |                                            |
|----------------|--------------------------------------------|
| <b>数据 / 模型</b> | <b>CIFAR-100 (20 超类) · ResNet-18 (预训练)</b> |
|----------------|--------------------------------------------|

---

|      |               |
|------|---------------|
| 遗忘目标 | 细类“火箭”(1 个类别) |
|------|---------------|

|      |                           |
|------|---------------------------|
| 数据划分 | forget (要忘) / retain (要留) |
|------|---------------------------|

|     |                             |
|-----|-----------------------------|
| 金标准 | Gold Model: 仅用保留数据重训的“理想遗忘” |
|-----|-----------------------------|

---

## 2 任务一·理解 Amnesiac

# Amnesiac Unlearning (基线)



## 原理

让模型把遗忘样本的标签换成随机错的，再微调几轮，原来对该类的正确映射就被覆盖掉。

## 具体做法：

1. 取遗忘类（火箭）的训练样本，逐个赋予**随机错误标签**；
2. 与保留数据混合，对原模型继续微调（少量 epoch）；
3. 遗忘类的判别被打乱，保留类基本不受影响.

## 我们要分析

学习率  $\in \{1e-3, 1e-4, 1e-5\}$ 、批大小  $\in \{128, 256, 512\}$ ，观察对“遗忘彻底性 vs 保留性能”的影响。

## 定位

最简单直接的基线，用来和 Bad Teacher、改进法对比。



## 3 任务二 · 复现 Bad Teacher

# 核心方法：双教师蒸馏



---

|           |                     |
|-----------|---------------------|
| 有能教师（原模型） | 保留样本 → 正确软标签 → 维持知识 |
|-----------|---------------------|

---

|            |                     |
|------------|---------------------|
| 无能教师（随机网络） | 遗忘样本 → 随机软标签 → 定向遗忘 |
|------------|---------------------|

---

学生按遗忘标记选择模仿对象，经带温度 KL 散度蒸馏 ( $T$  温度,  $\ell \in \{0, 1\}$ ):

$$p_{\text{tgt}} = \ell \cdot \text{softmax}\left(\frac{z_{\text{无能}}}{T}\right) + (1 - \ell) \cdot \text{softmax}\left(\frac{z_{\text{有能}}}{T}\right)$$

$$\mathcal{L} = \text{KL}\left(\text{logsoftmax}\left(\frac{z_{\text{学生}}}{T}\right) \parallel p_{\text{tgt}}\right)$$

# 我们补全的核心：蒸馏训练循环



`blindspot_unlearner` 里“模型更新 + 损失计算”这段是空的，由我们补全：

```
for x, y in loader:                # y=1 遗忘样本, y=0 保留样本
    with torch.no_grad():           # ① 两位老师冻结, 只给参考
        p_good = softmax(good_teacher(x) / T)    # 有能 = 原模型
        p_bad  = softmax(bad_teacher(x) / T)     # 无能 = 随机网络
    logit_s = student(x)            # ② 学生前向
    p_target = y * p_bad + (1 - y) * p_good       # ③ 逐样本挑老师
    loss = KL(log_softmax(logit_s / T), p_target)
    loss.backward(); opt.step(); opt.zero_grad() # ④ 只更新学生
```

1. 两位老师用 `no_grad` 冻结：只提供目标分布，本身不训练；
2. 关键在第 ③ 步：按标记 `y` 逐样本选目标 —— 遗忘样本学“无能”、保留样本学“有能”，温度 `T` 软化分布、传递更多信息；
3. 用 KL 散度把学生拉向目标分布，反传只更新学生。

## 4 任务三·完善评估指标

# 为什么还要两个额外指标



准确率只说明模型“答错了”，不代表它“没记住”——它可能只是嘴上不认、心里还记得。于是从两个角度补两把“尺子”：

## MIA（成员推断攻击）

站在攻击者视角，判断某条数据**是否被训练过**。模型对训练过的样本往往更自信；若攻击者已分辨不出，说明遗忘到位。**越低越好**。

## ZRF（零重训遗忘）

看模型对被删数据的反应，是否已接近一个**从没训练过的随机模型**。越接近，越说明忘得彻底。**越高越好**。

- 二者分别补上**隐私与行为分布**视角，并全部对照 Gold Model。

## 5 任务四·保留感知改进

# 动机：什么是“保留感知”



## 保留感知 (Retain-Aware)

遗忘的同时，主动“照看”要保留的类别、别让它们受连累。（保留 = 其余 19 类；感知 = 方法显式关注它们）

问题：纯 Bad Teacher 只顾着忘火箭 ——

- 对保留样本只做**软标签蒸馏**，监督偏弱；
- 结果**保留类准确率被一并拉低**（遗忘—保留张力：忘得越狠，越误伤该记的）。

# 设计：给保留方向加一道硬监督



办法直白：遗忘照旧，额外用真实标签把保留类“摠住”。

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{蒸馏}} + \lambda \cdot \text{CE}(f(\text{保留样本}), y_{\text{真}})$$

## 理由

真实标签（硬监督）比模仿老师（软标签）更强；与 SCRUB（2023）思路一致但更简洁；几乎零开销。

## 验证

$\lambda \in \{0, 0.5, 1, 2\}$  消融，对比纯 Bad Teacher。



## 6 进展与计划

# 阶段性进展



- 端到端框架、forget / retain 划分、Amnesiac 基线;
- 补全 Bad Teacher 蒸馏核心 (`unlearn.py`);
- 实现 MIA、ZRF 指标 (`metrics.py`);
- 保留感知改进的数据与损失、统一评估脚本。

```
loss = UnlearnerLoss(out, y, teacher_good, teacher_bad, T)           # Bad Teacher 核心
loss = kd_loss + lam * F.cross_entropy(out[retain], y_true[retain]) # 保留感知改进
mia = get_membership_attack_prob(...); zrf = compute_zrf(...)       # 两个指标
```



| 步骤  | 任务                      | 产出      |
|-----|-------------------------|---------|
| 第一步 | 五模型统一对比（含改进法）           | 对比表     |
| 第二步 | 超参 / $\lambda$ 消融，相关性分析 | 曲线图     |
| 第三步 | Gold Model 对照，结果分析      | 结论      |
| 第四步 | 结题报告、整理代码               | 报告 + 代码 |



| 方法          | Forget ↓ | Retain ↑ | MIA ↓ | ZRF ↑ |
|-------------|----------|----------|-------|-------|
| Gold (金标准)  | ≈随机      | 高        | 低     | 高     |
| Bad Teacher | 低        | 中        | 低     | 高     |
| 保留感知 (本文)   | 低        | 高        | 低     | 高     |

创新一：引入 MIA / ZRF，补齐“只看准确率”的短板

创新二：保留感知改进，缓解遗忘—保留张力

## 7 总结



**复现** —— Amnesiac + Bad Teacher (补全核心)

**评估** —— 补上 MIA、ZRF, 回答“是否真的忘了”

**改进** —— 保留感知: 有动机、可解释、可验证

- [1] Graves L., et al. Amnesiac Machine Learning. AAAI, 2021.
- [2] Chundawat V. S., et al. Can Bad Teaching Induce Forgetting? Unlearning in Deep Networks Using an Incompetent Teacher. AAAI, 2023.
- [3] Kurmanji M., et al. Towards Unbounded Machine Unlearning (SCRUB). NeurIPS, 2023.
- [4] Fan C., et al. SalUn: Empowering Machine Unlearning via Gradient-based Weight Saliency. ICLR, 2024.
- [5] Hayes J., et al. Inexact Unlearning Needs More Careful Evaluations to Avoid a False Sense of Privacy. arXiv, 2024.
- [6] Deep Unlearn: Benchmarking Machine Unlearning for Image Classification. arXiv, 2024.

# 感谢观看！

小组成员：李宇晗，窦宇浩