

面向图像分类模型的机器逆学习

方法复现、隐私评估与改进·隐私保护大作业

2026 年 8 月

组员 A · 组员 B

Contents



1 引入与分工	4
1.a 一句话概览	5
1.b 报告分工	6
2 研究背景与意义 (讲者 A)	8
2.a 从“删除数据”到“删除影响”	9
2.b 为什么不能直接重训?	10
2.c 金融科技场景中的意义	11
3 国内外研究现状 (讲者 A)	12
3.a 逆学习方法三大技术路线	13
3.b 评估的难点: 如何证明“真的忘了”	14
4 方法复现 (讲者 A)	15
4.a 实验设定	16
4.b 方法一: Amnesiac Unlearning	17
4.c 方法二: Bad Teacher (核心) — 双教师蒸馏	18
4.d Bad Teacher: 损失函数与核心代码	19

Contents (ii)



5 改进方法 (讲者 B)	21
5.a 动机: 纯 Bad Teacher 会“误伤”保留精度	22
5.b 改进: Retain-Aware Bad Teacher (本文方法)	23
6 评估指标 (讲者 B)	24
6.a 指标一: 成员推断攻击 MIA	25
6.b 指标二: 零重训遗忘分数 ZRF	26
7 实验与分析 (讲者 B)	27
7.a 主结果对比 (对照 Gold Model)	28
7.b 结果可视化	29
7.c 关键分析: 准确率不足以证明遗忘	30
7.d 超参数敏感性与消融	31
8 结论与展望 (讲者 B)	32
8.a 结论与贡献	33
8.b 谢谢 · Q&A	34

1 引入与分工

研究问题

让训练好的分类模型“忘掉”某一指定类别的数据影响，又不从头重训。

我们做了三件事：

1. 复现 两种主流机器逆学习方法 (Amnesiac、Bad Teacher)；
2. 实现 两个隐私 / 遗忘专用评估指标 (MIA、ZRF)，并以“重训模型”为金标准对照；
3. 改进 提出 Retain-Aware Bad Teacher，改善“遗忘彻底性—保留性能”折中。

关键词：被遗忘权 · 知识蒸馏 · 成员推断攻击 · 数据隐私

讲者	负责内容（约 3 分钟 / 人）
----	------------------

讲者 A	第 1 部分：选题与背景意义 → 研究现状 → 实验设定 → Amnesiac → Bad Teacher 方法与代码
------	---

讲者 B	第 2 部分：改进方法 → MIA / ZRF 指标 → 实验结果与分析 → 超参/消融 → 结论与展望
------	--

- 建议交接点：讲完 **Bad Teacher** 损失与代码（第 3 节末）后由 A 交棒给 B。
- 每张幻灯片下方的“讲点”即口播要点，照着说即可。



第一部分（讲者 A）

背景 · 现状 · 方法复现

2 研究背景与意义 (讲者 A)

从“删除数据”到“删除影响”



- GDPR 第 17 条“被遗忘权”、我国《个人信息保护法》：用户有权要求删除个人数据。
- 但删掉数据库里的样本 $\neq$ 删掉它对模型的影响——模型参数仍“记得”它。
- 攻击者可通过成员推断 / 模型反演从模型中恢复训练数据的存在性甚至内容。

合规删除必须落到模型层面的遗忘，这正是“机器逆学习”要解决的问题。

讲点：先抛合规痛点——法规要求“被遗忘”，但模型会“偷偷记住”，所以需要逆学习。

为什么不能直接重训？



最干净的做法是“删掉数据后从头重训”（即我们的金标准 Gold Model），但现实中：

计算代价高 大模型训练动辄数天、耗费巨额算力，频繁删除请求扛不住

响应太慢 合规常有时限，重训难以及时完成

数据不可得 完整训练集可能已不可用或分布式存储

目标

近似逆学习——以远低于重训的代价，让模型逼近“从未见过被删数据”的状态。

讲点：强调重训是“理想但昂贵”，逆学习是“够用且便宜”，这是全篇动机。

金融科技场景中的意义



- 合规删除：用户注销 / 行权后，其交易、征信、行为数据的影响需从风控、营销模型移除；
- 数据纠错：撤销错误标注、欺诈污染、偏见样本对模型的影响；
- 安全伦理：清除投毒 / 后门样本，提升模型鲁棒性与可信度。

讲点：把话题拉回“金融科技”，说明这不是玩具问题，而是风控/合规刚需。

3 国内外研究现状 (讲者 A)

逆学习方法三大技术路线



类别	代表方法	特点
精确逆学习	SISA 分片重训 (2021)	精确但需改造训练
参数修正	影响函数 / Fisher / SSD (2020-24)	理论优雅、估计代价大
微调 / 蒸馏	Amnesiac (2021)、Bad Teacher (2023)	最轻量、易落地 ★

- 本文选择微调 / 蒸馏路线：代价最低、最适合一晚完成的复现与改进。

讲点：给听众一张“地图”，说明我们选的是最实用的一支，并点名要复现的两篇。

评估的难点：如何证明“真的忘了”



“遗忘集准确率下降”只是必要非充分——模型可能只是“装作不会”，内部仍泄露信息。

三个评估维度：

有效性

遗忘集准确率 / 置信度是否降到接近随机；

保留性

保留集性能是否基本不受损；

隐私性

攻击者能否区分“遗忘后模型”与“从未训练过被删数据的模型”。

- 通行做法：以从头重训的 **Gold Model** 为金标准对照。

讲点：埋下伏笔——单看准确率不够，引出后面 B 要讲的 MIA / ZRF。

4 方法复现 (讲者 A)

实验设定



数据集	CIFAR-100 → 映射为 20 个超类
模型	ResNet-18 (ImageNet 预训练), 输入 224×224
遗忘目标	遗忘细类 <code>class 69</code> (火箭 Rocket, 属“交通工具”超类)
数据划分	forget_train / valid (火箭) + retain_train / valid (其余)
成功判据	Forget Acc ↓ 接近随机, Retain Acc 保持, MIA ↓、ZRF ↑, 逼近 Gold

讲点：用“忘掉火箭这个类，但别忘了其他 19 类”一句话把设定讲清楚。

方法一：Amnesiac Unlearning



思想：破坏模型对遗忘样本的正确映射。

1. 把 `forget` 样本的标签随机替换为其他类别；
 2. 与保留数据混合后，对原模型微调若干轮；
 3. 模型在“错误监督”下覆盖了对火箭类的原有认知。
- 优点：实现极简、开箱即用（基线）。
 - 后面会分析学习率 / 批大小对遗忘效果的影响。

讲点：Amnesiac 一句话——“故意教错，把记忆盖掉”，作为最简单的对照基线。

方法二：Bad Teacher（核心）— 双教师蒸馏



一个学生、两个教师：

有能教师 (原模型)	在保留样本上给正确软标签 → 学生保住知识
------------	-----------------------

无能教师 (随机初始化)	在遗忘样本上给近乎随机的软标签 → 学生“学会遗忘”
--------------	----------------------------

- 学生按样本的 forget / retain 标记，选择模仿哪个老师；
- 用带温度的 **KL** 散度蒸馏 → 保留数据维持、遗忘数据退化为随机响应。

讲点：这是全场最亮的点——“好老师教该记的，坏老师教该忘的”，务必讲清楚。

Bad Teacher: 损失函数与核心代码



设温度 T ，三方 logits 为 z_f （有能）、 z_u （无能）、 z_s （学生），遗忘标记 $\ell \in \{0, 1\}$ ：

$$p_{\text{target}} = \ell \cdot \text{softmax}(z_u/T) + (1 - \ell) \cdot \text{softmax}(z_f/T)$$

$$\mathcal{L}_{\text{KD}} = \text{KL}(\log_{\text{softmax}}(z_s/T) \parallel p_{\text{target}})$$

```
p_target = y * softmax(z_u/T) + (1-y) * softmax(z_f/T)    # 逐样本选教师
loss = KL(log_softmax(z_s/T), p_target)                  # 我们补全的核心
```

↑ 这一段蒸馏循环是我们自己补全的 **TODO** (`blindspot_unlearner`)

讲点：强调“这段代码是我们写的”，公式不必逐符号念，讲清 y 如何切换老师即可。交棒给 B。



第二部分（讲者 B）

改进 · 评估 · 实验分析

5 改进方法 (讲者 B)



动机：纯 Bad Teacher 会“误伤”保留精度

- 保留样本只靠“模仿”有能教师的软标签；
- 当遗忘类与保留类特征纠缠时，蒸馏信号带噪；
- 结果：遗忘干净了，但保留准确率往往一起掉。

我们的问题

能否在忘得干净的同时，把保留性能“锚住”？

讲点：先讲“痛点”，让听众理解改进是为了解决一个真实缺陷。

改进：Retain-Aware Bad Teacher（本文方法）



在原蒸馏损失上，为保留样本加一个监督交叉熵锚定项：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{KD}} + \lambda \cdot \text{CE}(\text{student}(\text{retain}), y_{\text{true}})$$

- 用保留样本的真实标签直接约束决策边界；
- 实现上新增 `UnLearningDataWithLabel`（携带真实标签）+ `blindspot_unlearner_retain_aware`；
- 几乎零额外开销， λ 控制“遗忘 $\leftrightarrow$ 保留”的权衡。

讲点：一句话——“忘的方向照蒸馏，保的方向加监督”，这是我们的创新点。

6 评估指标 (讲者 B)



指标一：成员推断攻击 MIA

直觉：模型对训练过的样本更自信（预测熵更低）。

1. 以每样本预测熵为特征；
2. 训练 SVM 攻击器区分“成员”(保留训练集) vs “非成员”(未见验证集)；
3. 让攻击器判断遗忘样本 → 输出“被判为成员的比例”。

MIA ↓ 越好

越低说明越难判断该数据曾被训练，隐私保护越好。

讲点：把 MIA 讲成“侦探”——遗忘成功后，侦探认不出火箭样本是不是训练过。

指标二：零重训遗忘分数 ZRF



直觉：完美遗忘的模型，对遗忘数据的反应应像一个从未训练过的随机网络。

$$\text{ZRF} = 1 - \frac{1}{|D_f|} \sum_{x \in D_f} \text{JS}(\text{student}(x) \parallel \text{teacher}_{\text{rand}(x)}) / \ln 2 \in [0, 1]$$

ZRF ↑ 越好

越接近 1 → 越像“未训练网络” → 遗忘越彻底。

- 与 MIA 相互印证：一个看隐私泄露，一个看行为分布。

讲点：ZRF 讲成“像不像新手”——越像随机网络，说明忘得越干净。

7 实验与分析 (讲者 B)

主结果对比（对照 Gold Model）



方法	Forget ↓	Retain ↑	MIA ↓	ZRF ↑
原始模型	高	高	高	低
Gold（金标准）	≈随机	高	低	高
Amnesiac	低	中—高	中	中
Bad Teacher	低	中	低	高
+Retain（本文）	低	高	低	高

数值以 `unlearning_results.csv` 实测替换；越接近 Gold 行越好。

讲点：先读表——本文方法在保住 Retain 的同时，隐私指标接近 Gold。

结果可视化



[fig_accuracy_comparison.png]

[fig_privacy_metrics.png]

Forget vs Retain 准确率

MIA / ZRF 隐私指标

讲点：指着左图说“红柱(遗忘)都降下来了”，右图说“我们的方法隐私指标最贴近 Gold”。

关键分析：准确率不足以证明遗忘



- 有效性：三种方法都能把 Forget Acc 打下来；
- 保留性：纯 Bad Teacher 会掉 Retain，本文改进把它拉回接近 Gold；
- 隐私性：MIA↓ 与 ZRF↑ 方向一致，互相印证；
- 重要发现：存在“Forget Acc 已很低、但 MIA 仍偏高”的情形 → 模型表面遗忘、内部仍记忆。

结论：隐私指标是对准确率的必要补充，只看准确率会高估遗忘效果。

讲点：这是全篇最有“研究味”的一句，务必强调——它回答了 A 埋的伏笔。

超参数敏感性与消融



Amnesiac 超参数

- 学习率过小 $\rightarrow$ 遗忘不足
- 学习率过大 $\rightarrow$ 误伤保留（灾难性遗忘）
- 存在最优折中区间

改进 λ 消融

- $\lambda = 0 \rightarrow$ 退化为 Bad Teacher
- $\lambda \uparrow \rightarrow$ 更偏保留、遗忘略保守
- 需在验证集择优

〔学习率 / λ 对 Forget-Retain 折中的影响曲线〕

讲点：说明我们做了敏感性与消融，方法不是“碰运气”， λ 可控地调节折中。

8 结论与展望 (讲者 B)

结论与贡献



1. 复现: Amnesiac + Bad Teacher, 自行补全双教师蒸馏核心;
2. 评估: 实现 MIA + ZRF, 结合 Gold Model 建立对照, 揭示“准确率不足以证明遗忘”;
3. 改进: Retain-Aware Bad Teacher 改善“遗忘—保留”折中, 几乎零额外开销。

局限: 单类遗忘、MIA 攻击较弱、规模有限、 λ 需调参。

展望: 多类 / 随机样本遗忘、更强攻击评估、更大模型与真实金融数据验证。

讲点: 三句话收束三大贡献, 主动说局限体现严谨, 展望留给提问缓冲。



感谢聆听，欢迎提问

代码: `unlearn.py` · `metrics.py` · `dataset.py` · `unlearn_and_eval.ipynb`

可能的提问方向: 为何用随机教师? MIA 是否够强? λ 如何选? 与 SISA/SSD 的区别?

讲点: 预判问题提前想好答案; 把代码文件名亮出来体现工作量。