

图像分类模型的机器逆学习

复现、评估与保留感知改进

2026 年 7 月 15 日

李宇晗 · 窦宇浩

Contents



1 研究背景与目标	3
2 任务一·理解 Amnesiac	7
3 任务二·复现 Bad Teacher	9
4 任务三·完善评估指标	13
5 任务四·保留感知改进	15
6 进展与计划	18
7 总结	22

1 研究背景与目标

- 合规与安全要求：从已训练模型中**移除某些数据的影响**（“被遗忘权”、修复被污染/错标的数据）；
- 但**删数据** $\neq$ **删影响**，而从头重训代价太高 $\rightarrow$ 催生“近似逆学习”；
- 现有方法多数只用**遗忘集准确率**判断成败，未必真忘（Hayes 2024）。

本文目标

让模型可靠地忘掉一个指定类别、保住其余类别，并能**验证**它真的忘了。

研究内容：四项任务



围绕指南的四项任务展开：

任务	内容
一·理解	运行 Amnesiac，调超参分析遗忘影响
二·复现	复现 Bad Teacher，补全其蒸馏训练核心
三·评估	在准确率外引入 MIA、ZRF 两个指标并分析
四·改进	提出“保留感知”改进，并对照验证

相关工作

本文沿**蒸馏路线** (Bad Teacher、SCRUB)，参照近年评估研究 (Hayes 2024、Deep Unlearn 2024) 补隐私指标；另有 SISA、SalUn 等路线可参考。

数据 / 模型	CIFAR-100 (20 超类) · ResNet-18 (预训练)
---------	-------------------------------------

遗忘目标	细类“火箭” (1 个类别)
------	----------------

数据划分	forget (要忘) / retain (要留)
------	---------------------------

金标准	Gold Model: 仅用保留数据重训的“理想遗忘”
-----	-----------------------------

2 任务一·理解 Amnesiac

Amnesiac Unlearning



原理

让模型把遗忘样本的标签换成随机错的，再微调几轮，原来对该类的正确映射就被覆盖掉。

具体做法：

1. 取遗忘类（火箭）的训练样本，逐个赋予**随机错误标签**；
2. 与保留数据混合，对原模型继续微调（少量 epoch）；
3. 遗忘类的判别被打乱，保留类基本不受影响.

全量 CUDA 结果（未训练 Gold）

Forget Acc 从原模型的 55.00% 降至 **7.00%**；Retain Acc 从 47.14% 升至 **60.02%**。

结论

本轮中 Amnesiac 是遗忘最强的基线，说明重标记微调能有效打乱目标类判别。

3 任务二 · 复现 Bad Teacher

核心方法：双教师蒸馏



它是复现的重点，也是后面“保留感知”改进的基础——比 Amnesiac 更可控、更有原理。

给一个学生模型配**两位老师**：

有能教师（原模型）	保留样本 → 正确软标签 → 维持知识
------------------	----------------------------

无能教师（随机网络）	遗忘样本 → 随机软标签 → 定向遗忘
-------------------	----------------------------

好老师守住“该记的”，坏老师带走“该忘的”。

全量 CUDA 结果

Bad Teacher 将 Forget Acc 降至 **22.00%**（原模型 55.00%），但 Retain Acc 为 47.67%，保留能力仍有提升空间。

损失设计：逐样本选老师 + 温度蒸馏



学生按遗忘标记 $\ell \in \{0, 1\}$ 逐样本选择模仿对象，用带温度 T 的 KL 散度蒸馏：

$$p_{\text{tgt}} = \ell \cdot \text{softmax}\left(\frac{z_{\text{无能}}}{T}\right) + (1 - \ell) \cdot \text{softmax}\left(\frac{z_{\text{有能}}}{T}\right)$$

$$\mathcal{L} = \text{KL}\left(\text{logsoftmax}\left(\frac{z_{\text{学生}}}{T}\right) \parallel p_{\text{tgt}}\right)$$

- **逐样本切换**： $\ell = 1$ （遗忘）学无能老师、 $\ell = 0$ （保留）学有能老师；
- **温度 T** ：软化输出、放大类别间关系，让蒸馏传递更丰富的信息。

我们补全的核心：蒸馏训练循环



`blindspot_unlearner` 里“模型更新 + 损失计算”这段是空的，由我们补全：

```
for x, y in loader:                # y=1 遗忘样本, y=0 保留样本
    with torch.no_grad():           # ① 两位老师冻结, 只给参考
        p_good = softmax(good_teacher(x) / T)    # 有能 = 原模型
        p_bad  = softmax(bad_teacher(x) / T)     # 无能 = 随机网络
    logit_s = student(x)             # ② 学生前向
    p_target = y * p_bad + (1 - y) * p_good       # ③ 逐样本挑老师
    loss = KL(log_softmax(logit_s / T), p_target)
    loss.backward(); opt.step(); opt.zero_grad() # ④ 只更新学生
```

1. 两位老师用 `no_grad` 冻结：只提供目标分布，本身不训练；
2. 关键在第 ③ 步：按标记 `y` 逐样本选目标 —— 遗忘样本学“无能”、保留样本学“有能”，温度 `T` 软化分布、传递更多信息；
3. 用 KL 散度把学生拉向目标分布，反传只更新学生。

4 任务三·完善评估指标

为什么还要两个额外指标



准确率只说明模型“答错了”，不代表它“没记住”——它可能只是嘴上不认、心里还记得。于是从两个角度补两把“尺子”：

MIA（成员推断攻击）

站在攻击者视角，判断某条数据**是否被训练过**。模型对训练过的样本往往更自信；若攻击者已分辨不出，说明遗忘到位。**越低越好**。

ZRF（零重训遗忘）

看模型对被删数据的反应，是否已**接近一个从没训练过的随机模型**。越接近，越说明忘得彻底。**越高越好**。

本轮结果（未训练 Gold）

MIA 在四种方法上均为 1.000，当前攻击配置已饱和、无法区分方法；ZRF 上 Bad Teacher 为 0.745、保留感知法为 0.702，均高于原模型 0.492。

5 任务四·保留感知改进

动机：什么是“保留感知”



保留感知 (Retain-Aware)

遗忘的同时，主动“照看”要保留的类别、别让它们受连累。（保留 = 其余 19 类；感知 = 方法显式关注它们）

问题：纯 Bad Teacher 只顾着忘火箭 ——

- 对保留样本只做**软标签蒸馏**，监督偏弱；
- 目标类虽能遗忘，但保留方向没有显式的真实标签约束，仍有优化空间。

全量 CUDA 对比

保留感知法的 Forget Acc 为 **23.00%**，与 Bad Teacher 的 22.00% 基本持平；Retain Acc 则从 47.67% 升至 **54.25%** (+6.58 个百分点)。

设计：给保留方向加一道硬监督



办法直白：遗忘照旧，额外用真实标签把保留类“摠住”。

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{蒸馏}} + \lambda \cdot \text{CE}(f(\text{保留样本}), y_{\text{真}})$$

理由

真实标签（硬监督）比模仿老师（软标签）更强；与 SCRUB（2023）思路一致但更简洁；几乎零开销。

验证

$\lambda \in \{0, 0.5, 1, 2\}$ 消融，对比纯 Bad Teacher。

6 进展与计划



- 端到端框架、forget / retain 划分、Amnesiac 基线;
- 补全 Bad Teacher 蒸馏核心 (`unlearn.py`);
- 实现 MIA、ZRF 指标 (`metrics.py`);
- 保留感知改进的数据与损失、统一评估脚本。
- 完成全量 CUDA 对照：保留感知法在近似遗忘效果下，将 Retain Acc 提升 6.58 个百分点。

```
loss = UnlearnerLoss(out, y, teacher_good, teacher_bad, T)           # Bad Teacher 核心
loss = kd_loss + lam * F.cross_entropy(out[retain], y_true[retain]) # 保留感知改进
mia = get_membership_attack_prob(...); zrf = compute_zrf(...)       # 两个指标
```

后续实验计划



步骤	任务	产出
第一步	训练 Gold Model, 补齐理想遗忘对照	完整对比表
第二步	多随机种子复现, 报告均值与方差	稳健性结果
第三步	超参 / λ 消融, 相关性分析	曲线图
第四步	结题报告、整理代码	报告 + 代码



方法	Forget ↓	Retain ↑	MIA ↓	ZRF ↑
Gold (金标准)	≈随机	高	低	高
Bad Teacher	低	中	低	高
保留感知 (本文)	低	高	低	高

创新一：引入 MIA / ZRF，补齐“只看准确率”的短板

创新二：保留感知改进，缓解遗忘—保留张力

7 总结



复现 —— Amnesiac + Bad Teacher (补全核心)

评估 —— 补上 MIA、ZRF, 回答“是否真的忘了”

改进 —— 保留感知: 有动机、可解释、可验证



- [1] Graves L., et al. Amnesiac Machine Learning. AAAI, 2021.
- [2] Chundawat V. S., et al. Can Bad Teaching Induce Forgetting? Unlearning in Deep Networks Using an Incompetent Teacher. AAAI, 2023.
- [3] Kurmanji M., et al. Towards Unbounded Machine Unlearning (SCRUB). NeurIPS, 2023.
- [4] Fan C., et al. SalUn: Empowering Machine Unlearning via Gradient-based Weight Saliency. ICLR, 2024.
- [5] Hayes J., et al. Inexact Unlearning Needs More Careful Evaluations to Avoid a False Sense of Privacy. arXiv, 2024.
- [6] Deep Unlearn: Benchmarking Machine Unlearning for Image Classification. arXiv, 2024.

感谢观看！

小组成员：李宇晗，窦宇浩